

Raport de rezultate și interpretare Tema 1 IA

Explorarea datelor (EDA)

1. Analiza tipurilor de atribute și a plajei de valori

Statistici pentru atribute numerice continue

	nr_ex_fara_val_lipsa	mean	std	min	25%	50%	75%	max
experience_years	64000	11.615703	11.031172	0.00000	5.000000	10.00000	16.00000	69.000000
skills_count	64000	9.974469	5.479935	1.00000	5.000000	10.00000	15.00000	19.000000
certifications	44853	2.497180	1.708064	0.00000	1.000000	3.00000	4.00000	5.000000
proficiencies	64000	9.950859	5.451872	1.00000	5.000000	10.00000	15.00000	19.000000
aggregated_score	64000	-0.004506	1.003307	-4.35271	-0.676323	-0.00686	0.67447	4.226987

Statisticile arată că variabilele numerice au distribuții diferite, cu experience_years având cea mai mare variație și valori extreme (maxim 69), în timp ce aggregated_score este centrat în jurul valorii 0, iar certifications are mai puține observații, indicând posibile valori lipsă care trebuie tratate în preprocesare.


Statistici pentru atribute discrete

	nr_ex_fara_val_lipsa	nr_val_unice
job_title	64000	12
education_level	64000	5
industry	64000	10
company_size	64000	5
location	64000	10
remote_work	64000	3
experience_bracket	64000	3

Se observă că variabilele categorice au cardinalitate redusă (3–12 valori unice), ceea ce facilitează procesul de encodare, neexistând valori lipsă, însă diferențele de cardinalitate pot influența contribuția fiecărei variabile în model.


Grafice de tip Boxplot pentru attributele numerice continue

Experience years




Din boxplot-ul pentru atributul `experience_years` se observă că majoritatea valorilor sunt concentrate între aproximativ 5 și 15 ani de experiență. Există însă valori extreme în partea superioară, în jurul valorilor 60–70, care sunt semnificativ mai mari decât restul distribuției. Aceste valori pot influența negativ modelele de tip regresie, deoarece acestea sunt sensibile la outlieri.

Skills Count



Distribuția atributului `skills_count` este relativ uniformă, fără prezența unor outliers semnificativi. Majoritatea valorilor sunt cuprinse între 5 și 15 competențe, ceea ce sugerează o variație moderată în numărul de skill-uri între exemple.

Aggregated Score




Boxplot-ul pentru atributul `aggregated_score` evidențiază prezența unor valori extreme atât în partea inferioară, cât și în partea superioară a distribuției. Acest lucru indică existența unor observații atipice, care pot afecta performanța modelelor, în special a celor sensibile la distribuția datelor. Distribuția pare relativ centrată în jurul valorii 0, dar dispersia mare sugerează o variabilitate ridicată a acestui atribut.


Grafice de tip histogramă pentru attribute categoriale

Pentru analiza atributelor categoriale am utilizat grafice de tip countplot, care evidențiază frecvența fiecărei categorii. Aceste grafice permit identificarea eventualelor dezechilibre și a categoriilor dominante sau rare.


Distribuție valori Job Title



Distribuție valori Education Level




Distribuție valori Industry



Din analiza acestor grafice se observă că distribuțiile sunt relativ uniforme, fără diferențe semnificative între frecvențele categoriilor. Acest lucru indică faptul că dataset-ul este echilibrat din punct de vedere al acestor atribute, neexistând categorii dominante sau subreprezentate. Din perspectiva modelării, această caracteristică este benefică, deoarece reduce riscul de bias al modelului către anumite categorii și contribuie la o generalizare mai bună a acestuia. În concluzie, attributele categoriale analizate sunt bine distribuite și nu necesită tratamente speciale pentru dezechilibru, însă vor necesita o codificare adecvată în etapa de preprocesare.


2. Analiza echilibrului de clase

Distribuția claselor pentru Vacation



Distribuția claselor este dezechilibrată, clasa No Vacation având un număr semnificativ mai mare de exemple comparativ cu celelalte clase, ceea ce poate influența negativ performanța modelului, favorizând predicțiile către această clasă majoritară.


Distribuția variabilei salary



Distribuția variabilei salary are o formă aproximativ normală, cu o ușoară asimetrie spre dreapta, majoritatea valorilor fiind concentrate în jurul intervalului mediu, dar existând și valori mari (outlieri) care pot influența modelul.

3. Analiza corelației între atribute

Matricea de corelație pentru atribute numerice



Am analizat corelația dintre atributele numerice folosind matricea de corelație. Se observă că majoritatea atributelor au corelații foarte reduse între ele, ceea ce indică faptul că acestea sunt în mare parte independente și nu există redundanță semnificativă în setul de date. O excepție este perechea **skills_count** și **proficiencies**, care prezintă o corelație foarte ridicată. Acest lucru sugerează că cele două variabile conțin informație similară și pot fi considerate redundante. În raport cu target-ul **salary**, corelațiile sunt slabe, cea mai mare fiind pentru **experience_years**, ceea ce sugerează o influență moderată asupra salariului.

Corelația între atributele numerice și sarcina de regresie (salary)

	Atribut	Corelație cu Salary
0	experience_years	0.229356
1	skills_count	0.128878
2	proficiencies	0.128757
3	certifications	0.072667
4	aggregated_score	0.001170


Am analizat corelația dintre atributele numerice și variabila țintă salary. Se observă că experience_years are cea mai mare corelație pozitivă cu salariul (~0.23), ceea ce indică faptul că experiența are un impact moderat asupra nivelului salarial. Atributele skills_count și proficiencies prezintă corelații mai reduse (~0.13), sugerând un impact mai mic asupra salariului. Certifications are o corelație slabă (~0.07), iar aggregated_score este practic necorelat cu salariul. În concluzie, niciun atribut nu are o corelație foarte puternică cu salariul, astfel corelațiile reduse indică faptul că regresia liniară simplă poate avea performanță limitată, fiind necesare modele mai complexe pentru a captura relațiile din date.

Corelație între atributele numerice și sarcina de clasificare (vacation)

	Atribut	Corelație cu Vacation
0	certifications	-0.001088
1	aggregated_score	-0.001833
2	proficiencies	-0.004704
3	skills_count	-0.004806
4	experience_years	-0.398735


Am analizat corelația dintre atributele numerice și variabila de clasificare vacation. Rezultatele arată că toate corelațiile sunt foarte apropiate de 0, ceea ce indică faptul că atributele numerice nu au o relație liniară puternică cu variabila țintă. Cea mai mare corelație este observată pentru experience_years (~ -0.39), însă aceasta rămâne moderată. Acest lucru sugerează că relația dintre variabile și eticheta de clasificare este mai complexă și probabil non-liniară, ceea ce justifică utilizarea unor modele mai avansate pentru clasificare.

Corelația dintre experience years și vacation (atribut numeric și sarcina de clasificare)




Se observă că persoanele cu mai mulți ani de experiență tind să aibă vacanțe mai mari, în timp ce cei cu experiență redusă apar mai des în categoria No Vacation. Totuși, valorile se suprapun între clase, ceea ce înseamnă că experiența nu este suficientă singură pentru a diferenția clar tipurile de vacanță.

Corelația dintre company size și vacation (atribut categorial și variabila de clasificare)




Se observă că în companiile mai mici (Small, Startup) predomină categoria No Vacation, în timp ce în companiile mari (Enterprise, Large) apare o proporție mai mare de vacanțe Medium și Large, ceea ce sugerează că dimensiunea companiei influențează vacanțele.

Corelația dintre experience years și salary (atribut numeric și variabila de regresie)



Se observă o tendință generală de creștere a salariului odată cu creșterea experienței, ceea ce indică o relație pozitivă între cele două variabile; totuși, există o variabilitate mare a valorilor, ceea ce arată că experiența nu este singurul factor care influențează salariul.

Corelația dintre job title și salary (atribut categorial și variabila de regresie)



Se observă diferențe între salarii în funcție de job, unele roluri precum AI Engineer și Machine Learning Engineer având, în general, salarii mai mari, în timp ce altele precum Data Analyst sau Business Analyst tind să aibă salarii mai mici; totuși, există variații în interiorul fiecărei categorii, ceea ce arată că jobul nu este singurul factor care influențează salariul.

Preprocesarea datelor

1. Tratarea valorilor lipsă

Pentru tratarea valorilor lipsă am utilizat metode de imputare diferite în funcție de tipul atributelor.

Pentru attributele numerice am folosit imputarea cu mediană. Această alegere este justificată prin faptul că distribuțiile atributelor numerice continuate conțin valori extreme, mediana fiind robustă la outlieri și oferă o estimare mai stabilă decât media.

Pentru attributele categoriale am utilizat imputarea cu cea mai frecventă valoare (modul), deoarece aceasta păstrează distribuția inițială a datelor.

Am integrat metodele de imputare într-un pipeline de preprocesare, pentru a asigura aplicarea consistentă a transformărilor atât pe datele de antrenare, cât și pe cele de validare.

Înainte de a alege aceste metode, am testat și alte variante de imputare, precum utilizarea mediei pentru attributele numerice sau eliminarea instanțelor cu valori lipsă. Aceste abordări au condus la rezultate mai slabe în performanța modelelor. Prin urmare, imputarea cu mediană și modul s-au dovedit a fi cele mai potrivite alegeri pentru acest set de date.

2. Tratarea valorilor extreme

Pentru identificarea valorilor extreme am utilizat metoda IQR (Interquartile Range). Pentru fiecare atribut numeric am calculat quartilele Q1 și Q3, iar valorile considerate outlieri au fost cele care depășesc intervalul:

$[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$.

În urma analizei, am identificat outlieri în special în atributul `experience_years` și într-o măsură mai mică în `aggregated_score`. Pentru tratarea acestor valori, am aplicat o metodă de clipping, prin care valorile extreme sunt aduse la limita inferioară sau superioară admisă. Această abordare permite păstrarea informației

din date, evitând eliminarea instanțelor și reducând impactul valorilor extreme asupra modelelor de învățare.

3. Standardizarea atributelor numerice

Am standardizat attributele numerice folosind StandardScaler, astfel încât să aibă media 0 și deviația standard 1. Această etapă este necesară deoarece attributele sunt scalate diferit, iar diferențele de scară pot afecta performanța modelelor.

4. Encoding pentru variabile categoricale

Am transformat attributele categoricale în variabile numerice folosind One-Hot Encoding. Astfel, creez câte o coloană binară pentru fiecare categorie, această abordare fiind potrivită în acest caz deoarece attributele categoricale nu au o ordine naturală. Astfel, evit introducerea unor relații artificiale de ordine între valori, ceea ce ar putea afecta negativ performanța modelelor.

Pentru variabila țintă din clasificare, **vacation**, am utilizat Label Encoding, transformând fiecare categorie într-o valoare numerică. Am făcut această alegere deoarece variabila țintă trebuie reprezentată numeric pentru a putea fi utilizată de algoritmii de clasificare, iar în acest context nu este necesară aplicarea One-Hot Encoding, deoarece modelul prezice direct eticheta clasei.

Utilizarea algoritmilor de Învățare Automată

Clasificare – predicția variabilei vacation

Am testat mai multe modele de clasificare, integrate într-un pipeline comun de preprocesare și antrenare.

Pentru a identifica cel mai potrivit model de clasificare, am realizat o serie de experimente pornind de la modele simple și crescând treptat complexitatea acestora.

Inițial, am folosit un arbore de decizie cu adâncime mică (`max_depth = 5`), pentru a obține un model simplu și ușor de interpretat. Rezultatele au arătat însă că modelul nu reușește să surprindă suficient de bine structura datelor, ceea ce indică un posibil underfitting.

Ulterior, am crescut adâncimea arborelui la `max_depth = 10`, pentru a permite modelului să învețe relații mai complexe. Această modificare a dus la o îmbunătățire a performanței, însă am observat o variație mai mare între rezultate, ceea ce sugerează apariția fenomenului de overfitting.

Pentru a controla acest comportament, am introdus parametrul `min_samples_leaf = 5`, limitând formarea frunzelor bazate pe un număr foarte mic de exemple. Această ajustare a condus la un echilibru mai bun între capacitatea de învățare și generalizare.

În paralel, am testat și un model liniar, Logistic Regression, pentru a avea un punct de referință (baseline). Acest model a oferit rezultate competitive, sugerând că există anumite relații aproximativ liniare în date.

În cele din urmă, am evaluat și un model mai complex, Random Forest, care combină mai mulți arbori de decizie. Acesta a fost ales pentru a verifica dacă o abordare bazată pe agregarea mai multor modele poate îmbunătăți performanța și stabilitatea rezultatelor.

Toate modelele au fost evaluate folosind aceleași date de antrenare și validare, precum și aceleași metrici (Precision, Recall și Scor F1 cu media macro), pentru a asigura o comparație corectă.

În urma acestor experimente, am selectat modelul care a obținut cele mai bune rezultate în funcție de scorul F1, considerat cel mai relevant în contextul unui set de date dezechilibrat.

În detaliu modelele utilizate au fost:

- **Decision Tree cu adâncime maximă 5**

Am utilizat acest model ca o variantă simplă, pentru a observa comportamentul unui arbore de decizie cu capacitate redusă. Cu o adâncime mică am limitat complexitatea modelului și am redus riscul de overfitting, însă această abordare poate duce la underfitting, relațiile din date fiind mai complexe

- **Decision Tree cu adâncime maximă 10**

Am crescut adâncimea arborelui pentru a permite modelului să surprindă relații mai complexe din date. Această variantă poate îmbunătăți performanța, dar crește și riscul de overfitting.

- **Decision Tree cu o constrângere în plus pe numărul minim de exemple din frunză (`min_samples_leaf = 5`) și adâncimea maximă tot 10**

Am introdus o constrângere suplimentară asupra numărului minim de exemple din fiecare frunză pentru a reduce overfitting-ul. Aceasta împiedică modelul să creeze noduri bazate pe foarte puține exemple și contribuie la o generalizare mai bună.

- **Logistic Regression cu maxim 2000 de iterații**

Am utilizat acest model ca punct de referință, deoarece este un model simplu și eficient, potrivit atunci când există relații aproximativ liniare între

variabile și variabila țintă. Din analiza exploratorie, am observat că anumite attribute (experience_years) au o corelație pozitivă cu ținta, chiar dacă nu este una foarte puternică, aceasta sugerează existența unor tendințe liniare. Am ales un număr mare de iterații pentru a asigura convergența algoritmului.

- **Random Forest cu 200 de arbori, fiecare având adâncime maximă de 10, care folosește toate nucleele de procesare**

Am utilizat acest model deoarece poate surprinde relații mai complexe între variabile, pe care un singur arbore de decizie sau un model liniar nu le poate capta. Fiind construit din mai mulți arbori, modelul este mai stabil și mai puțin sensibil la zgomotul din date. Am ales un număr mai mare de arbori pentru obținerea unor rezultate mai consistente, iar adâncimea am limitat-o pentru a ajuta la controlul complexității modelului.

Pentru a înțelege contribuția fiecărei alegeri de model, am realizat o analiză de tip ablație, comparând performanța algoritmilor și configurațiilor de hiperparametri.

Metrici de evaluare

Pentru evaluare am utilizat următoarele metrice:

- **Acuratețe** - reprezintă proporția predicțiilor corecte din totalul predicțiilor realizate de model
- **Precizie** - indică proporția predicțiilor corecte din totalul predicțiilor pozitive realizate de model, reflectând cât de corecte sunt predicțiile pentru o anumită clasă
- **Recall** - măsoară capacitatea modelului de a identifica corect toate exemplele care aparțin unei clase, raportând numărul predicțiilor corecte la totalul exemplelor reale din acea clasă.
- **Scor F1** - reprezintă media armonică între Precizie și Recall, oferind o măsură echilibrată a performanței modelului, mai ales în cazul datelor dezechilibrate.

Metricile Precizie, Recall și F1 le-am calculat folosind media macro, deoarece setul de date este dezechilibrat, iar această abordare tratează fiecare clasă în mod egal, calculând metricile pentru fiecare clasă, apoi făcând media simplă.

Compararea modelelor

	Model	Acuratețe	Precizie	Recall	F1
3	LogisticRegression	0.777750	0.709958	0.685770	0.696173
2	DecisionTree_leaf5	0.766500	0.701810	0.682289	0.691400
1	DecisionTree_depth10	0.764875	0.698908	0.679515	0.688560
4	RandomForest	0.751500	0.687742	0.640484	0.659222
0	DecisionTree_depth5	0.708000	0.640605	0.590069	0.610019

Alegerea celui mai bun model


Rezultatele arată că **Logistic Regression** oferă cea mai bună performanță, fiind ales ca cel mai bun model deoarece obține cel mai bun scor F1, are performanță consistentă pe toate metricile și generalizează mai bine decât modelele bazate pe arbori, fiind mai puțin predispus la overfitting.

Analiza performanței pe clase pentru cel mai bun model de clasificare găsit (Logistic Regression)

Tabel cu metricile calculate pentru fiecare clasă

	Class	Precision	Recall	F1	Support
0	Large	0.808161	0.770981	0.789133	1978
1	Medium	0.573326	0.465760	0.513975	2132
2	No Vacation	0.879233	0.931365	0.904549	8669
3	Small	0.579112	0.574977	0.577037	3221

Matricea de confuzie peste clase



Analiza performanței pe clase, susținută de matricea de confuzie, arată că modelul obține cele mai bune rezultate pentru clasa No Vacation, în timp ce între clasele Medium și Small apar cele mai multe erori de clasificare, confirmând dificultatea de separare a acestora și impactul dezechilibrului dintre clase asupra performanței generale, No Vacation având semnificativ mai multe exemple comparativ cu celelalte clase.

Regresie – predicția lui salary

Am testat mai multe modele de regresie, integrate într-un pipeline comun de preprocesare și antrenare (imputare, scalare și encoding), pentru a asigura consistența transformărilor aplicate datelor.

Pentru a identifica cel mai potrivit model, am realizat o serie de experimente pornind de la modele simple și crescând treptat complexitatea acestora.

Inițial, am utilizat Regresia Liniară ca model de bază (baseline), deoarece este ușor de interpretat și potrivită atunci când există relații aproximativ liniare între variabile. Rezultatele au fost bune, dar au sugerat că modelul poate fi îmbunătățit prin controlul mai atent al coeficienților.

Ulterior, am testat Ridge și Lasso Regression, introducând regularizarea pentru a reduce riscul de overfitting și a obține un model mai stabil. Ridge penalizează coeficienții mari și ajută la o mai bună generalizare, în timp ce Lasso poate elimina variabile mai puțin relevante, simplificând modelul.

În cele din urmă, am evaluat și un model mai complex, Random Forest Regressor, pentru a verifica dacă relațiile non-liniare pot aduce îmbunătățiri în performanță.

Toate modelele au fost evaluate folosind aceleași seturi de antrenare și validare, precum și aceleași metrici, pentru a permite o comparație corectă.

În detaliu modelele utilizate au fost:

- **Regresie Liniară**

Am utilizat acest model ca punct de referință, deoarece este cel mai simplu model de regresie și permite observarea relației liniare dintre variabilele de intrare și salariu.

- **Ridge Regression cu $\alpha = 1$ și $\alpha = 10$**

Am utilizat Ridge Regression pentru a introduce regularizare de tip L2, care penalizează coeficienții mari și ajută la reducerea overfitting-ului. Am testat două valori ale hiperparametrului α (1 și 10) pentru a observa impactul nivelului de regularizare asupra performanței modelului.

Valoarea $\alpha = 1$ oferă o regularizare moderată, în timp ce $\alpha = 10$ introduce o penalizare mai puternică, ceea ce duce la un model mai stabil și mai bine generalizat. Valorile lui α le-am selectat pentru a compensa corelațiile slabe dintre variabile și variabila țintă evidențiate în analiza exploratorie, regularizarea ajutând la stabilizarea coeficienților și la obținerea unui model mai robust.

- **Lasso Regression cu alpha = 0.001**

Am utilizat Lasso Regression pentru a introduce regularizare de tip L1, care are proprietatea de a reduce unii coeficienți la zero, realizând implicit o selecție de caracteristici. Am ales o valoare mică a lui alpha (0.001) pentru a evita eliminarea agresivă a variabilelor și pentru a păstra cât mai multă informație din date. Am testat acest model pentru a verifica dacă există attribute redundante care pot fi eliminate fără a afecta semnificativ performanța.

- **Random Forest Regressor**

Am utilizat acest model pentru a testa dacă relațiile dintre variabile sunt non-liniare și pot fi captate mai bine de un model bazat pe arbori. Am ales acest model pentru a compara performanța unui model complex cu cea a modelelor liniare și pentru a verifica dacă adăugarea complexității aduce îmbunătățiri. În acest caz, rezultatele au arătat că nu există beneficii semnificative, sugerând că datele nu necesită un model atât de complex.

Toate modelele au fost integrate într-un pipeline comun care include preprocesarea datelor (imputare, scalare și encoding), pentru a asigura aplicarea consistentă a transformărilor și o evaluare corectă a performanței.

Metrici de evaluare

Pentru evaluare am utilizat următoarele metrici:

- **MAE (Mean Absolute Error)** – reprezintă media valorilor absolute ale diferențelor dintre valorile reale și cele prezise, indicând în mod direct cât de mare este eroarea medie a modelului, fără a penaliza mai mult erorile mari
- **MSE (Mean Squared Error)** – calculează media pătratelor erorilor, penalizând mai puternic erorile mari, fiind util pentru a evidenția predicțiile care se abat semnificativ de la valorile reale
- **RMSE (Root Mean Squared Error)** – reprezintă rădăcina pătrată a MSE și este interpretabil în aceeași unitate ca variabila țintă (salariul), oferind o măsură mai intuitivă a erorii medii
- **R² (coeficient de determinare)** – măsoară cât de bine explică modelul variația datelor, indicând proporția din variabilitatea valorilor reale care este captată de model

Compararea modelelor

	Model	MAE	MSE	RMSE	R2
2	Ridge_alpha_10	6820.873430	7.702505e+07	8776.391627	0.944740
1	Ridge_alpha_1	6822.300732	7.703385e+07	8776.893070	0.944733
0	LinearRegression	6822.609344	7.703617e+07	8777.025337	0.944732
3	Lasso_alpha_0.001	6822.801365	7.703826e+07	8777.144140	0.944730
4	RandomForestRegressor	12206.951173	2.421473e+08	15561.082804	0.826275


Rezultatele arată că modelele liniare (Regresie Liniară, Ridge și Lasso) au performanțe foarte apropiate, în timp ce Random Forest obține rezultate semnificativ mai slabe, ceea ce confirmă ce s-a observat la explorarea datelor că relațiile din date sunt în mare parte liniare și nu necesită un model foarte complex.

Alegerea celui mai bun model

Se observă că Ridge Regression cu $\alpha = 10$ obține cele mai bune rezultate generale, având RMSE minim și R^2 maxim, ceea ce indică un echilibru bun între acuratețe și capacitatea de generalizare.


Analiza performanței celui mai bun model (Ridge Regression cu $\alpha = 10$)

Grafic valori reale vs prezise



Se observă că majoritatea punctelor sunt distribuite în jurul diagonalei, ceea ce indică faptul că modelul reușește să aproximeze bine relația dintre variabile și să ofere predicții apropiate de valorile reale. Totuși, pentru valorile mai mari ale salariului apare o ușoară dispersie.

Histograma erorilor pentru Ridge Regression cu alpha = 10




Histograma arată că majoritatea erorilor sunt concentrate în jurul valorii 0, ceea ce indică faptul că modelul face predicții, în general, apropiate de valorile reale. Distribuția este aproximativ simetrică și de tip normal, sugerând că nu există un bias puternic de supraestimare sau subestimare. Totuși, se observă și câteva valori extreme, ceea ce indică faptul că modelul poate avea erori mai mari pentru anumite instanțe.

Tabel train vs validation set

	Model	Train_MAE	Val_MAE	Train_RMSE	Val_RMSE	Train_R2	Val_R2
0	LinearRegression	6844.646883	6822.609344	8777.471092	8777.025337	0.944751	0.944732
1	Ridge_alpha_1	6844.539792	6822.300732	8777.495476	8776.893070	0.944751	0.944733
2	Ridge_alpha_10	6843.660286	6820.873430	8777.620322	8776.391627	0.944749	0.944740
3	Lasso_alpha_0.001	6844.708389	6822.801365	8777.495461	8777.144140	0.944751	0.944730
4	RandomForestRegressor	11817.981194	12206.951173	15156.259331	15561.082804	0.835272	0.826275

Grafic comparație train vs validation set



Se observă că modelele liniare au performanțe similare și generalizează bine, diferențele dintre train și validation fiind foarte mici. Modelul Ridge cu $\alpha = 10$ obține cele mai bune rezultate, având RMSE minim și R^2 maxim. RandomForest are performanțe semnificativ mai slabe, indicând o nepotrivire pentru acest set de date.